


2025년 11월 14일

뉴스 데이터 학습을 통한 가짜 뉴스 분류

Team 1 : Whiplash





가짜 뉴스의 심각성



정의

상업적/정치적 의도를 가진 거짓 정보 또는 의도적 잘못된 정보.



경제적 피해

실제 기사 중 1%가 가짜 뉴스로 유포될 경우 30조 900억 원 피해 추정



대응 노력

방송통신위원회, 가짜뉴스 신고 창구 및 패스트트랙 추진.

기존 시스템의 한계 및 연구 목표

현재 대응 시스템의 한계

01

신고 접수

가짜 뉴스 신고 창구를 통해 접수됩니다.

02

심의 진행

신속 심의 및 후속 구제 조치가 이루어집니다.

03

포털 공유

주요 포털 사업자에게 공유되어 조치를 요청합니다.

04

선제적 조치


필요시 포털 사업자가 선제적 조치를 취합니다.

현재 시스템은 수동적 신고 체계이며, 주관적 의견에 의존한다는 비판이 있습니다.

본 연구의 목표

인공지능 모델을 활용하여 가짜 뉴스 탐지 및 분류.


- Word2Vec, FastText, SROBERTa 모델 성능 비교 분석.
- 임무1: 기사 제목과 본문 부정합 여부 판별.
- 임무2: 뉴스 본문 중 맥락에 관계없는 내용 판별.



관련 연구: 딥러닝 기반 기술

단어 임베딩(Word Embedding)


텍스트 단어를 수치화하여 컴퓨터가 이해하도록 변환하는 방법.



이미지 출처: <https://qdrant.tech/articles/what-are-embeddings/>

컨볼루션 신경망 (CNN)

이미지 처리에서 필터링, 풀링, 분류를 통해 학습하는 계층 모델.



단어 임베딩 모델




Word2Vec

- 단어를 벡터로 표현, 문맥적 유사성을 학습하여 단어 간 관계 파악
- 비슷한 문맥으로 쓰이는 단어들은 가까운 벡터로 표현
 - CBOW. (Continuous Bag of Words) : 주변 단어로 중심단어 예측
 - Skip-Gram : 중심단어로 주변 단어 예측
- 학습이 완료되면 각 단어는 n차원 벡터로 변환



FastText

- Word2Vec의 한계 극복, 단어를 하위 단위(n-gram)로 쪼개어 학습
- 단어 전체뿐 아니라 단어 내부의 형태소 정보도 벡터로 학습
- Word2Vec과 마찬가지로 CBOW 또는 Skip-Gram 구조를 사용한다. 하지만 입력 단위가 단어가 아닌 subword 집합.



SROBERTa

- RoBERTa 기반 문장 임베딩에 특화, 문장 유사도 비교에 최적화
- 두 문장의 임베딩 벡터 간의 거리가 두 문장의 의미적 유사도와 일치하도록 모델을 학습
- 비슷한 문장은 사이의 거리를 가깝게. 다른 문장 사이의 거리는 멀게.

신경망 구성 및 학습 데이터


데이터셋

- 중앙일보, 동아일보 등 약 10만 개 뉴스 기사.
- 임무1: 31,000여 개 기사.
- 임무2: 68,000여 개 기사.



신경망 구성

- 3가지 모델(Word2Vec, FastText, SROBERTa)로 학습된 벡터 사용
- Convolution, Pooling 및 FC를 거쳐 분류 진행.
- 활성화함수는 Relu, 분류를 위한 활성화함수는 Softmax 를 사용.



연구 결과: Word2Vec 모델

작업 단계



- Embedding Matrix 구성 : Tokenizer를 통해 단어 인덱스를 매핑하고, Word2Vec 임베딩을 numpy 행렬로 변환
- 하이브리드 모델 (BiLSTM + CNN) : 순차적 문맥(LSTM)과 지역적 패턴(CNN)을 동시에 학습하는 구조 구현

주요 설정

- CNN 병렬 구조 : 3.4.5 크기 필터 각각 64개
- Optimizer : Adam(learning rate = 1e-4)
- 임베딩 차원 (EMBED_DIM) : 128
- 최대 시퀀스 길이 (MAXLEN) : 500
- 단어 수 제한 (NUM_WORDS : 30,000)
- L2 정규화 : 0.001

작업 결과

	Mission1	Mission2
Accuracy	0.51	0.61
AUROC	0.50	0.68



연구 결과: FastText 모델

작업 단계



- news의 'title'과 'content'를 결합한 문장을 token화하여 FastText 학습용 corpus를 구축함
- 하이브리드모델 (**TextCNN + Cosine Feature**) : FastText Embedding을 입력 받아 CNN을 통해 문맥적 pattern을 추출

주요 설정

- CNN 병렬 구조 : 3.4.5 크기 필터 각각 128개
- Optimizer : Adam(learning rate = 1e-3
- Embedding 가중치(vector_dim) = 100
- <pad> Index(0) 고정 및 gradient 미갱신
- 드롭아웃 비율 : 0.5

작업 결과

	Mission1	Mission2
Accuracy	0.47	0.82
AUROC	0.46	0.90



연구 결과: SRoBERTa 모델

작업 단계



- 모델의 성능 향상을 위해 임무1, 임무 2에 관한 모델 각각의 하이퍼파라미터 조정을 2회에 걸쳐서 진행
- Hugging Face에서 모델을 가져왔기에 TrainingArguments를 사용해서 하이퍼파라미터를 지정

주요 설정


- Learning rate : $3e-5$ (1차) -> $2e-5$ (2차)
- Per device train/eval batch size : 4(1차) -> 8(2차)
- Logging steps : 100(1차) -> 199(2차)
- Load best model at end : False(1차) -> True(2차)
- Metric for best mode : -(1 차) -> eval_auroc(2차)

작업 결과

	Mission1		Mission2	
	1차	2차	1차	2차
Accuracy	0.49	0.77	0.76	0.81
AUROC	0.46	0.84	0.82	0.86




주요 연구 결과: 모델 성능 비교



SRoBERTa 모델이 가장 높은 성능을 보였습니다.



결론



"SRoBERTa는 한글 가짜뉴스 탐지에서 뛰어난 잠재력을 보여줌"

개발 후기

주제 선정

- 프로젝트 초기, 주제 선정 과정에서 어려움을 겪음
- 단순한 주제 선택이 아닌 타깃과 해결 범위를 명확히 설정하는 것이 중요하고 이러한 설정이 프로젝트의 방향성과 설득력에 직접적인 영향을 끼친다는 것을 배움
- 해당 작업에 필요한 논문을 찾는 것이 작업 성공을 위한 가장 중요한 요소

작업

- 논문 검색과 분석 경험이 부족해 초반에는 다소 어려움
- 배우지 않은 모델은 논문 및 외부 자료를 통해 스스로 학습하고 적용해보면서 새로운 모델을 사용해야하는 상황에 어떻게 학습해야하는지 배울 수 있었음
- 하이퍼 파라미터 튜닝에 따른 모델 성능 변화를 직접 확인하며 파라미터 튜닝의 중요성을 알게 됨

아쉬운점 및 각오

- 학원에서의 첫 팀장 역할이었어서 서툰 부분이 있었을 것이라고 생각함. 이번 경험을 바탕으로, 추후 팀장을 맡게 된다면 더 나은 방식으로 팀을 이끌고 싶음
- 향후에 데이터를 보강해서 모델 성능을 재검증해보고 싶음
- 프로젝트를 통해 본인이 모델을 선정하고 수치를 개선하기 위한 방안을 찾는 과정에서 부족한 점을 많이 느낌



Q & A

감사합니다.

